

Separación de Fuentes por Análisis Estadístico

Objetivo Principal

- A diferencia de las técnicas de Beamforming, estas técnicas no necesitan conocer mucho del ambiente.
 - Varias, si no es que todas, ni siquiera asumen saber el número de fuentes existentes.
 - Aunque su desempeño puede mejorar al saberlo.
- Ya que no conocen mucho del ambiente, también se les conoce como Separador Ciego de Fuentes.
 - *Blind Source Separation*

Objetivo Principal

- La idea es encontrar a W :

$$\hat{S} = W X$$

Donde:

s_x : es la estimación de las señales de origen

X : son las señales capturadas (en los micrófonos); cada renglón representa un micrófono

W : es la matriz de separación (*demixing matrix*)

Donde...

$$\mathbf{A} = \begin{bmatrix} e^{-i2\pi f T_{1:1}} & e^{-i2\pi f T_{1:2}} & \dots & e^{-i2\pi f T_{1:D}} \\ e^{-i2\pi f T_{2:1}} & e^{-i2\pi f T_{2:2}} & \dots & e^{-i2\pi f T_{2:D}} \\ \vdots & \vdots & \ddots & \vdots \\ e^{-i2\pi f T_{M:1}} & e^{-i2\pi f T_{M:2}} & \dots & e^{-i2\pi f T_{M:D}} \end{bmatrix}$$

$$\mathbf{S} = \begin{bmatrix} s_1(1) & s_1(2) & \dots & s_1(N) \\ s_2(1) & s_2(2) & \dots & s_2(N) \\ \vdots & \vdots & \ddots & \vdots \\ s_D(1) & s_D(2) & \dots & s_D(N) \end{bmatrix}$$

$$\mathbf{X} = \mathbf{S} \mathbf{A}$$

Donde:

s_d : es una señal de origen

N : tamaño de la señal (o de la ventana de la señal)

$T_{m:d}$: es el retraso recibido de la señal s_d en el micrófono m

A: es la matriz que contiene los vectores de dirección (*direction vectors*)

X: son las señales capturadas (en los micrófonos); cada renglón representa un micrófono

Técnicas Populares

- Principal Component Analysis
- Independent Component Analysis
- Non-negative Matrix Factorization

Principal Component Analysis (PCA)

Principal Component Analysis

- Se asume que las señales de origen no están correlacionadas.
 - Visto de otra manera: que casi no se empalman.
 - Primer luz roja.
- Con esta suposición, propone a la W como aquella que pueda desmezclar a X en señales que son ortogonales.

Principal Component Analysis

- Ortogonalidad:
 - Los eigenvectores de una matriz son ortogonales entre sí.
- PCA propone utilizar los eigenvectores de la matriz de covariancia como W .
 - Como los utilizados para MUSIC.
- El resultado es la descomposición de X en sus *componentes principales*.
 - Que se asume **algunas** de ellas son las señales de origen.

Principal Component Analysis

Centramos las señales de entrada X , y así R sería la matriz de covariancia.

$$R = XX^T$$

$$R = V\Lambda V^{-1} \quad V = \begin{bmatrix} v_1 & v_2 & \cdots & v_K \end{bmatrix} \quad \Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_K \end{bmatrix}$$

$$\hat{S} = V' X$$


\hat{S} : los componentes principales de X ; un renglón por componente.

Tendrá tantos componentes como señales capturadas.


Tantos componentes como señales capturadas...

- ¿Cómo sabemos cuáles componentes son las estimaciones de las señales de origen?
- ¿Recuerdan a MUSIC?
 - Recordatorio: el eigenvalor es la cantidad de información de la matriz que representa el eigenvector.
 - Igual como con MUSIC, se ordenan los eigenvalores de manera acumulativa, divididos por su suma:
 - Si D es el arreglo de eigenvalores ordenados:
`plot(sumcum(D/sum(D)))`
 - Se busca algo cercano a un punto de inflexión.


Presentación de Eigenvalores



Presentación de Eigenvalores



Presentación de Eigenvalores



¿En serio? ¿De nuevo?

- Como MUSIC:
 - La decisión de cuántos eigenvectores utilizar es un problema tanto abierto.
- Pero, para esta fase, dicha decisión se podría simplificar:
 - Si estamos estimando los DOAs anteriores a este paso, también podemos saber cuántas señales de origen hay en el ambiente.
 - Desgraciadamente...

Ejercicio #1

- Descarguen:
pca.m
- Contiene una implementación de PCA:
 - Figura 1: las señales de origen
 - Figura 2: las señales de origen superpuestas con el **primer** y **tercer** componente.
 - Figura 3: una señal de origen superpuestas con el **segundo** componente.

Ejercicio #1

- ¿Qué problema ven?

Ejercicio #1

- ¿Qué problema ven?
- Los componentes no están completamente bien.
 - Parecen distorsionados, sin haber presencia de ruido.
 - Esto es porque hay algo de empalme entre ellos.
 - Pero no está mal.
 - Es importante mencionar que esta implementación magnifica los componentes al final, para mejor visualización.
- *Los componentes que son las estimaciones no son los dos con el mayor eigenvalor.*

Principal Component Analysis

- Un problema fuerte de PCA es la selección de componentes a señal de origen estimada:
 - Recordemos que normalmente no vamos a tener las señales de origen como referencia.
 - Por lo que no podemos saber si un componente es una estimación de una señal de origen, o sólo un componente de algún subespacio escondido.

Principal Component Analysis

- Problema de Permutación:
 - Si queremos hacer esto en línea, entonces esta decisión puede impactar no sólo a la ventana de audio actual, sino también a las que siguen.
 - En la una ventana la primera señal estimada puede provenir del primer componente, pero puede provenir de otro componente en la siguiente ventana.
 - Se requiere “seguir” a las señales estimadas a lo largo de las ventanas para asignar los componentes adecuados a éstas.
 - Esto no es para nada trivial.

Independent Component Analysis (ICA)

Independent Component Analysis

- Es el “primo lejano” de PCA.
- Su suposición es que los componentes son **independientes** entre sí.

Independencia

- Ejemplo: hay una gran correlación entre los siguientes sucesos:
 - Hay mucho viento
 - Turbinas de viento girando rapidamente
- Ahora, imaginen que no conocen los factores de la Física tras una turbina de viento.
 - Sólo están observando los sucesos...

Independencia

- ¿Cuál **causa** a cuál?
 - ¿El viento rota a las turbinas? ¿Las turbinas crean viento?
 - ¿Cuál es la *dirección de causalidad*?
 - Mejor dicho: ¿cuál **depende** de cual?
 - O, ¿es pura coincidencia que los dos sucesos ocurran al mismo tiempo?
 - Mejor dicho: ¿son sucesos **independientes**?
- Afortunadamente, es posible *medir* dicha independencia directamente de lo observado.

Independent Component Analysis

- La idea entonces es obtener una matriz de separación W tal que al aplicar a X , los componentes que resulten sean lo más independientes posibles.
 - Llamados Componentes Independientes.

Independent Component Analysis

- Independencia implica no-correlación:
 - Los componentes siguen teniendo que ser poco correlacionados.
 - Por lo que tampoco le gusta el empalme.
- Pero ese no es su mayor problema...

Medir la Independencia

- Hay varias formas de hacerlo, pero una muy popular es:
 - La reducción de **información mutua** entre las señales
 - La cual a su vez se puede medir por medio de la diferencia entre la *entropía de una señal dado la otra* y la *entropía conjunta de las dos señales*.
 - También conocida como la **entropía diferencial**.

¿Qué?!

- Fue exactamente lo que yo dije cuando leí ese enunciado.
- Sinceramente, podría entregarles toda una explicación de cómo implementarla, pero...

Ejercicio #2

- Descarguen:
ica.m
- Es una implementación de ICA:
 - Figura 1: señales de origen.
 - Figura 2: suponiendo que son sólo dos componentes independientes, aquí los muestra.

Ejercicio #2

- Dura un rato en correr:
 - Busca la matriz de separación de una manera iterativa.
- Hay una variable que pueden modificar:
do_not_delay
 - Si tiene valor 1: no desfasa a las señales de origen, sólo les modifica su magnitud.
 - Si tiene valor 0: desfasa las señales.

Ejercicio #2

- Correrlo con:
`do_not_delay = 1`

Ejercicio #2

- Correrlo con:
`do_not_delay = 1`
- Aunque lento, hace mucho mejor trabajo que PCA.
- Requiere correrse varias veces para obtener resultados apropiados.
 - Para eso la línea “`rand('seed',0.0005)`”.

Ejercicio #2

- Correrlo con:
do_not_delay = 0

Ejercicio #2

- Correrlo con:
do_not_delay = 0
- ???????
 - Ni siquiera se acerca...

Independent Component Analysis

- Por eso, mejor ni se acerquen a esta técnica para estos propósitos.

Non-negative Matrix Factorization (NNMF)

Non-negative Matrix Factorization

- La suposición es:
 - No hay valores negativos.
 - En ningún lado.
 - Ni en los componentes separados, ni en la matriz de separación W .

Non-negative Matrix Factorization

- Hacemos que X no tenga valores negativos:

$$X = X - \min(X)$$

- Proponemos inicialmente \hat{S} con valores al azar.
- Luego, repetimos los siguientes pasos *ad nauseam* o hasta que el error se minimize:

$$1) \quad \mathbf{W} = \mathbf{X} \hat{\mathbf{S}}^T (\hat{\mathbf{S}} \hat{\mathbf{S}}^T)^{-1} \quad 3) \quad \hat{\mathbf{S}} = (\mathbf{W}^T \mathbf{W})^{-1} \mathbf{W}^T \mathbf{X}$$

$$2) \quad \mathbf{W} (W < 0) = 0 \quad 4) \quad \hat{\mathbf{S}} (\hat{S} < 0) = 0$$

- El error lo medimos por medio de:

$$error = \|\mathbf{X} - \mathbf{W} \hat{\mathbf{S}}\|$$

Ejercicio #3

- Descarguen:
nnmf.m
- Es una implementación de NNMF, entregando el mismo tipo de figuras que ica.m

Ejercicio #3

- Correrlo con:
do_not_delay = 1

Ejercicio #3

- Correrlo con:
`do_not_delay = 1`
- Sólo entrega una buena estimación de una señal.
 - Ni así entrega buenos resultados.
 - Es una técnica que es muy sensible al empalme.

Ejercicio #3


- Correrlo con:

`do_not_delay = 0`

Ejercicio #3

- Correrlo con:
do_not_delay = 0
- ???????
 - Peor aún...

¿Que está sucediendo?



No están funcionando...

- Estas técnicas toman a cada renglón de X como una observación en forma de vector.
 - Y cada columna representa a **una dimensión de dichos vectores**.
- Suponen que las variaciones con las que van a lidiar, son sólo de magnitud en la misma dimensión entre señales.

No están funcionando...

- En nuestro caso, estamos lidiando mayormente con desfasamiento.
- Esto implica que se están comparando magnitudes que no pertenecen a la misma dimensión.
 - Esto rompe desde la raíz a estas técnicas.
 - Inconsistencias del tipo magnitud-a-dimensión.

Solución Tentadora: Versión en Frecuencia

- Las inconsistencias en el dominio del tiempo que vemos al aplicar un desfase **deberían** desaparecer en el dominio de la frecuencia.
 - ¿No?
- ¿Qué sucede si aplicamos estas técnicas en el dominio de la frecuencia?

PCA en Frecuencia

- Descarguen:
pca_fft.m
- Contiene una implementación de PCA con FFT:
 - Figura 1: las señales de origen
 - Figura 2: las señales de origen superpuestas con el **primer** y **tercer** componente.
 - Figura 3: una señal de origen superpuestas con el **segundo** componente.

PCA en Frecuencia

- ¿Esto se ve conocido?
- Compárenlo con PCA en tiempo...

PCA en Frecuencia

- Es igual.
 - Excepto por el segundo componente.
- ¿Nos podremos escapar del problema de desfase?
 - Probemos otra técnica en FFT...

ICA en Frecuencia

- Descarguen:
ica_fft.m
- Contiene una implementación de ICA con FFT:
 - Figura 1: señales de origen.
 - Figura 2: suponiendo que son sólo dos componentes independientes, aquí los muestra.

ICA en Frecuencia

do_not_delay = 1

- Parece ser más rápido.
 - No se la crean...
- Sólo encontró un componente, y la “tendencia” del otro.
- Diferentes resultados que con ICA en el tiempo.

ICA en Frecuencia

- La *entropía diferencial* se comporta diferente en el dominio del tiempo que en el de la frecuencia dadas las mismas señales.
 - El espacio de búsqueda es diferente entre los dominios.
 - Por lo tanto, la trayectoria al minimizarla es diferente.
- Seguramente se quedó atascado en un óptimo local.
 - Por eso pareció terminar más rápido.

ICA en Frecuencia

do_not_delay = 0

- Siguen estando muy mal separados.
- Compárenlo con ICA en tiempo...

ICA en Frecuencia

- Es igual, de nuevo.
- Ya van dos, pero todavía tenemos otra técnica a probar...

NNMF en Frecuencia

- Descarguen:
 nnmf_fft.m
- Contiene una implementación de NNMF con FFT:
 - Figura 1: señales de origen.
 - Figura 2: suponiendo que son sólo dos componentes, aquí los muestra.

NNMF en Frecuencia

do_not_delay = 1

- ???
 - ¿Ni así?
- Para ser justos, estamos violando la suposición principal de NNMF:
 - No valores negativos.
 - Esto no tiene sentido para números complejos.

NNMF en Frecuencia sólo Magnitud

- NNMF se podría utilizar utilizando sólo la magnitud:
 - Descarguen `nnmf_fft_mag.m`
- Contiene una implementación de NNMF con FFT utilizando sólo magnitud:
 - Figura 1: señales de origen en FFT.
 - Figura 2: suponiendo que son sólo dos componentes en FFT, aquí los muestra.

NNMF en Frecuencia sólo Magnitud

- Al correrlo con `do_not_delay = 1`:
 - Hay una separación entre los picos.
 - Desgraciadamente, por sólo utilizar la magnitud, hemos hecho al lado la fase, que es esencial para regresar al dominio del tiempo.
- Aún así, es sensible al estado inicial de las variables.
 - Para eso la línea de `“rand('seed',0.00026)”`

NNMF en Frecuencia sólo Magnitud

- Se podría incorporar el concepto de números complejos, pero otro supuesto fuera de no-negatividad se tendría que utilizar.
- Una variación en el dominio complejo de NNMF se puede encontrar en:

H. Kameoka, Nobutaka Ono, Kunio Kashino and Shigeki Sagayama, "Complex NMF: A new sparse representation for acoustic signals," 2009 IEEE International Conference on Acoustics, Speech and Signal Processing, Taipei, 2009, pp. 3437-3440.

- Antes de explorar otras alternativas de NNMF, es importante que lo probemos con `do_not_delay = 0` ...

NNMF en Frecuencia sólo Magnitud

- Al correrlo con `do_not_delay = 0`:
 - Ningún componente es separado.
- Aún en el dominio de la frecuencia, el desfase impacta a la separación.
- Por lo tanto, se puede intuir que la variación compleja de NNMF también va a ser impactada por el desfase.

¿Entonces no nos podemos escapar del desfase?

Desfase en Frecuencia

- El desfase también modifica a la señal en el dominio de la frecuencia.
 - Pero esto no se ve cuando sólo vemos la magnitud de las frecuencias.
- En donde se modifica es en la fase.

Desfase en Frecuencia

- Descarguen:
`test_delay_in_fft.m`
- Contiene una de las señales de origen y una versión desfasada:
 - Figura 1: señales en magnitud de frecuencia.
 - Figura 2: señales en fase de frecuencia.

Desfase en Frecuencia

- En la magnitud no hay diferencia.
- Pero sí la hay en la fase.
 - Ésta es la razón por la que NMF funciona bien si sólo utilizamos la magnitud.
- Entonces: no nos podemos escapar de la fase.

Es importante recordar...

- Ninguna de estas técnicas usa la información de dirección de arribo.
 - Recordemos que por su nulo uso de información extra se les conoce como técnicas de **separación ciega** (*Blind Source Separation*).
- ¿No sería posible utilizar esa información de desfase para nuestro beneficio en vez de nuestro perjuicio?

Solución Híbrida:
Geometric Source Separation
(GSS)

Geometric Source Separation

- Busca una matriz de separación W , pero en su búsqueda, aplica las siguientes dos restricciones:
 - Las fuentes tienen que ser poco correlacionadas.
 - Como en el caso de PCA e ICA.
 - El producto punto entre W y el direction vector A (de la estimación Multi-DOA hecho a-priori) debe ser 1.
 - El W es, a la vez, una matriz de separación y un steering vector de un beamforming múltiple.

Geometric Source Separation

- Ambas restricciones son aplicadas de una manera “suave”.
 - Se utiliza un algoritmo tipo LMS.
 - Como en GSC.
 - Las restricciones se aplican como funciones de costo.
- La estimación final de W no necesariamente cumple con estas restricciones.
 - Pero es cercano a hacerlo.

Geometric Source Separation

Búsqueda de W

W se actualiza en cada ventana de tiempo por medio de:

$$W_{t+1} = W_t - \mu (\|X\| \nabla J_1 + \nabla J_2)$$

Donde:

$$\nabla J_1 = 4 E W_t R_{xx}$$

$$\nabla J_2 = 2 (W_t A - I) A$$

$$R_{xx} = X X^T$$

$$E = R_{ss} - \text{diag}(R_{ss})$$

$$R_{ss} = S S^T$$

$$S = W_t X$$

Este proceso se tiene que llevar a cabo para cada frecuencia f.

También:

S: es la salida del sistema (GSS)

X: son las señales capturadas

A: es el direction vector que indica en qué direcciones están las señales de origen

W_t : es la matriz de separación utilizada en la ventana actual

W_{t+1} : es la matriz de separación a ser utilizada en la siguiente ventana

μ : constante de adaptación

$\text{diag}()$: función que regresa en un vector los valores en la diagonal de una matriz: $\text{diag}\left(\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}\right) = \begin{bmatrix} 1 \\ 4 \end{bmatrix}$

$$\text{Por cierto: } \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} - \begin{bmatrix} 1 \\ 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} - \begin{bmatrix} 1 & 1 \\ 4 & 4 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$

Desgraciadamente...

- Como pueden ver, su implementación es compleja.
- Y esta es la versión básica del algoritmo.
- Los proyectos ManyEars y HARK utilizan una variación aún mas compleja.
- Por lo tanto:
 - Su implementación va más allá del nivel de complejidad apropiado para este curso.

Espera...

- ¿Esto significa que los algoritmos de análisis estadístico puros no son útiles para separación de fuentes defasadas en línea?
 - Éste es un tema todavía no completamente resuelto en la literatura de análisis estadístico.
 - Por lo tanto, considerando sólo las versiones presentadas en este curso (las originales):
 - *Estas técnicas no son útiles para nuestros propósitos.*

¿Entonces? ¿Proyecto final?

- La intención de las sesiones de *Separación de Fuentes* es proporcionar el campo completo de todas las alternativas que se han considerado.
 - Que las versiones presentadas aquí no sean viables, no significa que no haya alguna versión que sí lo sea.
 - Hay decenas de ellas: sería interesante explicar/explorar cada una, pero no para ámbitos pedagógicos como las de este curso.
- **Entonces:** es bastante claro que, por ahora, las opciones más convenientes para nuestros propósitos son del tipo de Beamforming.

Excepto...

- Si alguno de ustedes implementa exitosamente en JACK la versión presentada aquí de Geometric Source Separation:
 - En la página del curso está un artículo que lo explica detalladamente aplicado en un robot de servicio.
 - Es la versión utilizada en ManyEars.
- O alguna versión más reciente.
- Definitivamente merecen el 100 en este curso.
 - Reto presentado...

Siguiente Clase:

Descripción del Proyecto Final